

AI Chapter 9: Uncertainty

Autonomous Agents (স্বয়ংক্রিয় এজেন্ট)

In the context of Artificial Intelligence and Logic, Uncertainty can be defined as a state where an agent (like a computer or a robot) lacks enough information to make a 100% certain decision or prediction.

Unlike traditional logic, which only knows True or False, uncertainty deals with the "gray areas" of the real world.

◆ 1. Autonomous Agent কী?

Autonomous Agent হলো এমন একটি system বা entity, যা নিজে নিজে environment (পরিবেশ) থেকে তথ্য নেয়, সিদ্ধান্ত নেয় এবং কাজ (action) করে — মানুষের continuous control ছাড়াই।

👉 সহজভাবে:

একটা "smart system" যেটা নিজে চিন্তা করে, দেখে, বুঝে এবং কাজ করে।

📌 Example:

🚗 Self-driving car (স্বয়ংচালিত গাড়ি)

Real World Example: Driving Agent

একটা **self-driving car** কিভাবে কাজ করে সেটা দিয়েই Autonomous Agent বোঝা সহজ।

🧠 2. Reasoning & Decision Making

Driving agent সবসময় ৩টা কাজ করে:

1. **Perceive** (দেখা/অনুভব করা)
2. **Think / Reason** (বিশ্লেষণ করা)

3. Act (কাজ করা)

👉 অর্থাৎ:

“কি দেখলাম → কি বুঝলাম → কি করবো”

3. Sensors (ইনপুট নেওয়ার অংশ)

Sensors হলো agent-এর “চোখ-কান” 👁️👂

Driving agent যেসব sensor ব্যবহার করে:

Camera

- রাস্তা, গাড়ি, মানুষ, সিগন্যাল দেখে

Tachometer

- গাড়ির speed (গতি) মাপে

Engine Status Sensor

- ইঞ্জিন ঠিক আছে কিনা দেখে

Temperature Sensor

- ইঞ্জিন বা বাইরের temperature মাপে

📌 সহজভাবে:

Sensors = তথ্য সংগ্রহ করার মাধ্যম

4. Effectors (আউটপুট / কাজ করার অংশ)

Effectors হলো agent-এর “হাত-পা” 🦾

Driving agent যেগুলো দিয়ে কাজ করে:

Accelerator

- গাড়ির speed বাড়ায়

Brakes

- speed কমায় / গাড়ি থামায়

Steering

- গাড়ির দিক পরিবর্তন করে

 সহজভাবে:

Effectors = কাজ বাস্তবায়ন করার অংশ

5. Model of World (বিশ্বের ধারণা)

Agent নিজের মাথায় একটা “world model” বানায়:

এতে থাকে:

-  Vehicle location & status
-  Road status (রাস্তা কেমন আছে)

 অর্থ:

Agent বাস্তব পৃথিবীকে নিজের ভিতরে একটা “mental map” হিসেবে রাখে

6. Actions (কাজ / সিদ্ধান্ত)

Agent যেসব কাজ করতে পারে:

-  Change speed (গতি বাড়ানো/কমানো)
-  Change steering (দিক পরিবর্তন)

 অর্থ:

Decision নেওয়ার পর সেটা action এ convert হয়

7. Prior Knowledge (আগের জ্ঞান)

Agent আগে থেকেই কিছু knowledge জানে:

Physics of movement

- গাড়ি কিভাবে চলে, brake করলে কি হয়

Rules of road

- ট্রাফিক আইন, সিগন্যাল মানা

 অর্থ:

“আগে শেখা knowledge decision নিতে help করে”

8. Goal (লক্ষ্য)

সব autonomous agent-এর একটা goal থাকে:

 Example:

Drive home (বাড়ি পর্যন্ত নিরাপদে পৌঁছানো)

 অর্থ:

সব decision শেষ পর্যন্ত goal পূরণের জন্য

CLICK SLIDE: Uncertainty in the World Model

9. বিশ্ব সবসময় **uncertain** (অনিশ্চিত)

Agent কখনোই 100% নিশ্চিত হতে পারে না যে পৃথিবীতে কি হচ্ছে।

 কেন?

কারণ বাস্তব world imperfect

Why uncertainty happens?

1. Sensors have limited precision

- camera সবকিছু perfect detail এ ধরতে পারে না
- pixel সীমিত

 Example:

দূরের গাড়ি blur দেখা যায়

2. Sensors have limited accuracy

- tachometer speed আনুমানিক দেখায়
- exact value নাও হতে পারে

 Example:

Speed 60 km/h হলেও sensor দেখাতে পারে 58 বা 62

3. Hidden Variables (লুকানো তথ্য)

কিছু জিনিস sensor দেখতে পারে না:

 Example:

- বড় ট্রাকের পেছনে অন্য গাড়ি লুকানো
 - storm cloud আসছে কিন্তু এখন দেখা যাচ্ছে না
-

4. Future is unknown

 ভবিষ্যৎ কখনোই fully predictable না

 Example:

- সামনে হঠাৎ মানুষ রাস্তা পার হতে পারে
 - accident হতে পারে
-

FINAL SIMPLE SUMMARY

Autonomous Agent হলো এমন system যা:

-  Sensors দিয়ে environment দেখে
 -  world model বানায়
 -  prior knowledge ব্যবহার করে
 -  goal অনুযায়ী সিদ্ধান্ত নেয়
 -  effectors দিয়ে action নেয়
 -  কিন্তু সবসময় uncertainty থাকে
-



ONE LINE EXAM ANSWER

Autonomous agent is a system that perceives its environment through sensors, builds a world model, makes decisions using reasoning and prior knowledge, and acts using effectors to achieve a goal under uncertainty.



Rules and Uncertainty (নিয়ম এবং অনিশ্চয়তা)



1. Simple Rule-Based Reasoning

ধরা যাক আমাদের একটা rule আছে:



If toothache then problem is cavity

এটার মানে:

যদি কারো দাঁতে ব্যথা হয়, তাহলে ধরে নেওয়া যায় তার cavity (দাঁতের ক্ষয়) আছে।



Problem: Real life is not perfect

কিন্তু বাস্তব জীবনে সবসময় এটা সত্য না ❌



সব toothache-এর কারণ cavity না

কারণ হতে পারে:

- gum disease (মাড়ির রোগ)
 - filling problem (আগের ভরাট নষ্ট)
 - sensitivity
 - infection
-



2. Complex Rule Approach (Problematic Method)

আমরা চাইলে rule আরও বড় করতে পারি:

👉 if toothache AND NOT gum disease AND NOT filling AND ...
→ then cavity

📌 কিন্তু সমস্যা:

- অনেক অনেক condition যোগ করতে হয়
- rule অনেক বড় হয়ে যায়
- maintain করা কঠিন হয়ে যায় 😞

👉 এই সমস্যাকে বলে:

Combinatorial Explosion (rules অতি জটিল হয়ে যাওয়া)

🎯 3. Better Approach: Probability (সম্ভাবনা ভিত্তিক নিয়ম)

এর চেয়ে ভালো উপায় হলো:

👉 if toothache then cavity (probability = 0.8)

অর্থাৎ:

📌 $P(\text{cavity} \mid \text{toothache}) = 0.8$

🧠 এর মানে কী?

👉 যদি কারো toothache থাকে,
তাহলে 80% chance আছে সে cavity-তে আক্রান্ত

📌 এটা নিশ্চিত না (not 100%), বরং likelihood

🔥 Key Idea:

- ✓ Logic = yes/no (true/false)
 - ✓ Probability = degree of belief (0 to 1)
-

⚠️ **CLICK SLIDE: Uncertainty in World Model**

4 Types of Uncertainty

1. True Uncertainty (আসল অনিশ্চয়তা)

👉 বাস্তব জগৎ inherently uncertain

📌 Example:

- dice rolling 
- coin flipping 

👉 এগুলো predict করা যায় না exactly

2. Laziness (গবেষণায় অলসতা / complexity)

👉 সব rule বের করা খুব কঠিন

কারণ:

- সব exception খুঁজে বের করা কঠিন
- অনেক factors থাকে

📌 Example:

Medical diagnosis rule লিখতে গেলে হাজারো condition লাগে

👉 তাই আমরা simplify করি

3. Theoretical Ignorance (তত্ত্বই জানা নেই)

👉 আমরা সব rules জানি না

📌 Example:

Medical science

- অনেক disease-এর exact cause এখনো unknown
- complete theory নেই

👉 তাই perfect rule বানানো সম্ভব না



4. Practical Ignorance (data নেই)

👉 theory জানা থাকলেও data incomplete

📌 Example:

Doctor জানে disease সম্পর্কে সব কিছু
কিন্তু patient-এর সব test result নেই

👉 তাই decision uncertain হয়



CLICK SLIDE: Logics



5. Different Types of Logic

Logic system আলাদা হয় কারণ তারা আলাদা “world view” (primitives) ব্যবহার করে

Logic হলো কতগুলো নিয়মের সমষ্টি যা ব্যবহার করে আমরা কিছু জানা তথ্য (Known Facts) থেকে নতুন এবং নিশ্চিত কোনো সিদ্ধান্তে (Inference) পৌঁছাতে পারি।



Table Explanation (easy version)

1. Propositional Logic

- শুধু facts থাকে
- true / false / unknown

📌 Example:

It is raining → True/False

2. First-Order Logic (FOL)

- facts + objects + relations

📌 Example:

Doctor treats Patient

👉 এখানে relation আছে

3. Temporal Logic (সময় যুক্ত logic)

- time element যোগ হয়

📌 Example:

It will rain tomorrow

👉 past, present, future বিবেচনা করা হয়

4. Probability Theory

- belief থাকে 0 থেকে 1 এর মধ্যে

📌 Example:

0.8 chance of rain ☔

👉 uncertainty handle করে

5. Fuzzy Logic

- truth “partial” হতে পারে

📌 Example:

Temperature is HOT

👉 hot কতটা hot? 70% hot, 30% not hot



FINAL SIMPLE SUMMARY

👉 Real world rules are not perfect

👉 তাই logic-এর সাথে probability যোগ করতে হয়

👉 Uncertainty আসে 4 কারণে:

- true randomness
- complexity (laziness)
- lack of theory
- lack of data

👉 Different logics represent different types of knowledge:

- true/false logic
- object-relation logic
- time-based logic
- probability belief

- fuzzy partial truth
-



ONE LINE EXAM ANSWER

Uncertainty in AI arises because real-world rules are not deterministic; therefore probabilistic reasoning (e.g., $P(\text{cavity}|\text{toothache})=0.8$) and different logic systems are used to represent incomplete, uncertain, or partial knowledge.



Probability Theory (সম্ভাবনা তত্ত্ব)



1. Probability Theory কী?

👉 Probability theory হলো এমন একটি mathematical framework, যার মাধ্যমে আমরা uncertain (অনিশ্চিত) knowledge কে represent করি এবং reasoning করি।



সহজভাবে:

Probability theory ব্যবহার করা হয়—

- কোন কিছু ঘটার chance (সম্ভাবনা) বোঝার জন্য
 - belief (বিশ্বাসের degree) quantify করার জন্য
 - uncertain decision নিতে
-



Example:

ধরা যাক:

- রোগ নির্ণয় (diagnosis)
- weather prediction 🌧️
- AI decision making 🤖

👉 সব জায়গায় uncertainty থাকে, তাই probability ব্যবহার করা হয়

🎯 Key Idea:

👉 Probability = degree of belief (0 থেকে 1)

- 0 → impossible ❌
- 1 → certain ✅
- 0.5 → uncertain ⚖️

🧠 CLICK SUB: Utility Theory

💠 2. Utility Theory (উপযোগিতা তত্ত্ব)

👉 Utility মানে হলো “কতটা useful বা লাভজনক একটা state”

📌 Concept:

👉 Every state (অবস্থা) এর একটা utility value থাকে

- বেশি utility = বেশি preferred 👍
- কম utility = less preferred 👎

🚗 Example:

একটা self-driving car ভাবো:

State	Utility
Safe driving 🚗	High utility
Accident risk ⚠️	Low utility
Traffic jam 🚦	Medium utility

👉 Agent সবসময় high utility state choose করতে চায়

CLICK SUB: Decision Theory

3. Decision Theory (সিদ্ধান্ত তত্ত্ব)

👉 Decision theory বলে:

একজন agent rational (যুক্তিসঙ্গত) হবে যদি সে এমন action নেয় যা সর্বোচ্চ expected utility দেয়।

 সহজভাবে:

👉 Agent এমন কাজ করবে যা ভবিষ্যতে সবচেয়ে বেশি লাভ দিবে (on average)

Expected Utility মানে কী?

👉 সম্ভাব্য সব outcome এর average utility (probability অনুযায়ী weighted)

Example:

ধরা যাক car সামনে decision নিচ্ছে:

Action A: Speed up

- 70% safe → high utility
- 30% accident → very low utility

Action B: Slow down

- 90% safe → medium-high utility
- 10% delay → low loss

👉 Agent যেটার expected utility বেশি, সেটাই choose করবে

Decision Theory

- **Action 1: Drive fast**

- Arrive on time (80% chance) → Utility = 100

- Get into an accident (20%) → Utility = 0

- Expected Utility = $0.8 \times 100 + 0.2 \times 0 = 80$

- **Action 2: Drive slow**

- Arrive late but safe (100%) → Utility = 60

- Expected Utility = $1.0 \times 60 = 60$

Final Definition:

 Decision Theory = Probability Theory + Utility Theory

 অর্থ:

- probability → uncertainty handle করে
- utility → preference/benefit handle করে
- combined → best decision making

Kolmogorov's Axioms of Probability

1. $0 \leq P(a) \leq 1$

probabilities are between 0 and 1 inclusive


2. $P(\text{true}) = 1, P(\text{false}) = 0$

probability of 1 for propositions believed to be absolutely true

probability of 0 for propositions believed to be absolutely false

3. $P(a \vee b) = P(a) + P(b) - P(a \wedge b)$

probability of two states is their sum minus their “intersection”



11

CLICK SUB: Kolmogorov's Axioms of Probability

🧠 Probability এর 3টি basic rules

📌 1. Range Rule

👉 $0 \leq P(a) \leq 1$

অর্থ:

- probability কখনো 0 এর কম বা 1 এর বেশি হতে পারে না

📌 Example:

- $P(\text{rain}) = 0.7$ ✓
- $P(\text{rain}) = -0.2$ ✗
- $P(\text{rain}) = 1.3$ ✗

2. Certain & Impossible Events

👉 $P(\text{true}) = 1$

👉 $P(\text{false}) = 0$

Example:

- সূর্য উঠবে $\rightarrow P = 1$ ☀️
 - $2+2 = 5 \rightarrow P = 0$ ❌
-

3. Addition Rule

👉 $P(a \cup b) = P(a) + P(b) - P(a \cap b)$

🧠 সহজভাবে:

👉 দুইটা event একসাথে overlap করলে double count হয়, তাই overlap বাদ দিতে হয়

Example:

ধরা যাক:

- $P(\text{rain}) = 0.4$
- $P(\text{cloudy}) = 0.5$
- $P(\text{rain AND cloudy}) = 0.2$

👉 তাহলে:

$$P(\text{rain OR cloudy}) = 0.4 + 0.5 - 0.2 = 0.7$$

FINAL SUMMARY

- ✎ Probability theory uncertainty handle করে belief measure করে
- ✎ Utility theory preference বা usefulness measure করে
- ✎ Decision theory এই দুইটা combine করে best action বের করে
- ✎ Kolmogorov axioms probability-এর basic mathematical rules define করে



ONE LINE EXAM ANSWER

Probability theory models uncertain belief (0–1), utility theory assigns value to states, and decision theory combines both to choose actions with maximum expected utility, based on Kolmogorov's axioms of probability.

Inference Using Full Joint Distribution

- Start with the joint probability distribution:

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	.108	.012	.072	.008
$\neg$ <i>cavity</i>	.016	.064	.144	.576



Inference Using Full Joint Distribution

(Full Joint Probability Distribution দিয়ে Inference)

◆ 1. Full Joint Distribution কী?

- ✎ Full Joint Distribution মানে হলো:
একসাথে সব variables-এর সব possible combination-এর probability table।

📌 Example world:

- Toothache (T)
- Cavity (C)
- Catch (K)

👉 আমরা সব combination-এর probability আগে থেকেই জানি

🧠 সহজভাবে:

👉 এটা হলো “সব possible situation-এর probability map”



Example Idea:

আমাদের কাছে দেওয়া আছে:

- $P(T, C, K)$
- $P(T, C, \neg K)$
- $P(T, \neg C, K)$
- $P(T, \neg C, \neg K)$

👉 এগুলোর যোগফল থেকেই আমরা inference করি



CLICK SUB: Inference by Enumeration

◆ 2. Inference by Enumeration কী?

Inference by Enumeration হলো অনেকটা ফিল্টার করার মতো। তোমার কাছে সব ডাটা আছে, তুমি শুধু তোমার টার্গেট শব্দ (এক্ষেত্রে 'Toothache') যেখানে যেখানে সত্যি, সেই সম্ভাবনাগুলো যোগ করে দিলে।



Example: $P(\text{toothache})$

আমরা toothache-এর probability বের করবো:

👉 Toothache যেসব case-এ আছে সেগুলো যোগ করবো:

[
P(toothache) = 0.108 + 0.012 + 0.016 + 0.064
]



Calculation:

[
P(toothache) = 0.2
]



Meaning:

👉 Toothache হওয়ার মোট probability = 0.2 (20%)



Key Idea:

👉 Enumeration = সব relevant row add করা

Inference by Enumeration



- Start with the joint probability distribution:

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	.108	.012	.072	.008
$\neg$ <i>cavity</i>	.016	.064	.144	.576

- Can also compute conditional probabilities:

$$\begin{aligned}
 P(\neg \text{cavity} \mid \text{toothache}) &= \frac{P(\neg \text{cavity} \wedge \text{toothache})}{P(\text{toothache})} \\
 &= \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} \\
 &= 0.4
 \end{aligned}$$



CLICK SUB: Conditional Probability

3. Conditional Probability

👉 আমরা এখন বের করবো:

[
 $P(\neg \text{cavity} \mid \text{toothache})$
]



Formula:

[
 $P(A|B) = \frac{P(A \wedge B)}{P(B)}$
]



Step-by-step:

- Step 1: Numerator ($\neg \text{cavity} \wedge \text{toothache}$)

$$[\\ P(\\neg \\text{cavity} \\wedge \\text{toothache}) = 0.016 + 0.064 = 0.08 \\]$$

♦ **Step 2: Denominator (toothache)**

$$[\\ P(\\text{toothache}) = 0.2 \\]$$

♦ **Step 3: Final result**

$$[\\ P(\\neg \\text{cavity} \\mid \\text{toothache}) = \\frac{0.08}{0.2} = 0.4 \\]$$

 Final Meaning:

👉 যদি toothache থাকে, তাহলে 40% chance আছে cavity নেই

Independence



- Independence between propositions a and b can be written as:
 $P(a \mid b) = P(a)$ or $P(b \mid a) = P(b)$ or $P(a \wedge b) = P(a) P(b)$
- Independence assertions are usually based on knowledge of the domain.
- As we have seen, they can dramatically reduce the amount of information necessary to specify the full joint distribution.
- If the complete set of variables can be divided into independent subsets, then the full joint can be *factored* into separate joint distributions on those subsets.
- For example, the joint distribution on the outcome of n independent coin flips, $P(C_1, \dots, C_n)$, can be represented as the product of n single-variable distributions $P(C_i)$.



CLICK SUB: Independence

◆ 4. Independence কী?

👉 দুইটা event independent হলে, একটার উপর অন্যটার কোনো effect নেই

📌 Mathematical definitions:

✓ 1. Conditional form:

$$\begin{bmatrix} P(a \mid b) = P(a) \\ \end{bmatrix}$$

✓ 2. Symmetric form:

$$\begin{bmatrix} P(b \mid a) = P(b) \\ \end{bmatrix}$$

✓ 3. Product form:

[
 $P(a \text{ \& } b) = P(a)P(b)$
]

🧠 সহজভাবে:

👉 একটার occurrence অন্যটাকে affect করে না

📌 **Example:**

- Coin toss 🎲
- Dice roll 🎲

👉 একটার outcome অন্যটার সাথে সম্পর্ক নেই

⚠ Important Concept:

👉 Independence usually আসে domain knowledge থেকে

📌 মানে:

- আমরা data দেখে decide করি কোন variables independent
-

📈 Why Independence is Important?

👉 Full joint distribution অনেক বড় হয়:

- n variables → exponential size 🤯
-

🎯 Independence helps:

👉 Complexity কমা়় dramatically

CLICK SUB: Factorization of Joint Distribution

5. Factoring Full Joint

👉 যদি variables independent হয়:

$$[P(C_1, C_2, \dots, C_n) = \prod P(C_i)]$$

Meaning:

👉 পুরো joint distribution কে ছোট ছোট parts এ ভাগ করা যায়

Example:

If independent:

$$[P(A, B, C) = P(A)P(B)P(C)]$$

Benefit:

- Storage কম লাগে 
 - Computation fast হয় 
 - AI inference সহজ হয় 
-

FINAL SUMMARY

- 👉 Full joint distribution = সব possible world-এর probability table
- 👉 Inference by enumeration = relevant cases যোগ করা
- 👉 Conditional probability = ratio method দিয়ে inference

- 👉 Independence = variables unrelated
 - 👉 Independence helps factor joint distribution → reduces complexity
-



ONE LINE EXAM ANSWER

Inference using full joint distribution computes probabilities by summing relevant entries of the joint table, conditional probabilities are derived using Bayes rule form, and independence assumptions allow factorization of the joint distribution into simpler products of individual probabilities.



Bayes' Theorem (বেইজ উপপাদ্য)



1. Basic Idea (মূল ধারণা)

Bayes' Theorem হলো এমন একটা mathematical rule, যা দিয়ে আমরা **new evidence** (নতুন তথ্য) পেয়ে আগের belief update করি।

👉 অর্থাৎ:

“আগে যা জানতাম + নতুন তথ্য → **updated probability**”



2. Basic Probability Relationship

আমরা জানি:



Joint probability দুইভাবে লেখা যায়:

$$\begin{aligned} [& \\ P(A \text{ \& } B) &= P(A|B)P(B) \\] & \end{aligned}$$

$$\begin{aligned} [& \\ P(B \text{ \& } A) &= P(B|A)P(A) \\] & \end{aligned}$$

Important insight:

👉 দুইটাই একই ঘটনা ($A \cap B$), শুধু দৃষ্টিভঙ্গি (perspective) আলাদা

Bayes' in Action (Bayes' ব্যবহার বাস্তবে)

1. Bayes' Rule কেন দরকার?

👉 Bayes' theorem ব্যবহার করতে আমাদের লাগে:

📌 3টা probability:

1. একটি **conditional probability** (শর্তযুক্ত probability)
 2. দুটি **unconditional probability** (prior + evidence)
-

 সহজভাবে:

👉 একটা unknown probability বের করতে আমরা অন্য 3টা জানা probability ব্যবহার করি

Key Idea:

👉 "We use known probabilities to compute unknown probability"

2. Bayes' Rule কেন practical?

👉 বাস্তব জীবনে আমরা অনেক সময় এই 3টা probability সহজেই estimate করতে পারি:

- ✓ $P(A|B) \rightarrow$ conditional (cause-effect relation)
 - ✓ $P(A), P(B) \rightarrow$ unconditional (overall frequency)
-

 তারপর আমরা বের করি:

👉 missing probability (posterior)

Example intuition:

ধরা যাক medical diagnosis 🏥

আমাদের জানা থাকতে পারে:

- রোগ থাকলে symptom হওয়ার probability
- রোগের overall frequency
- symptom কতবার দেখা যায়

👉 কিন্তু আমরা চাই:

- symptom থাকলে রোগের probability
-

3. Medical Diagnosis (সবচেয়ে important use case)

Problem:

Doctor-এর লক্ষ্য:

👉 রোগ নির্ণয় করা (diagnosis)

What we usually know:

- ✓ $P(\text{symptom} \mid \text{disease})$
 - ✓ $P(\text{disease})$
 - ✓ $P(\text{symptom})$
-

But we want:

👉 $P(\text{disease} \mid \text{symptom})$

🔥 That is exactly Bayes' Theorem:

$$[P(\text{disease}|\text{symptom}) = \frac{P(\text{symptom}|\text{disease})P(\text{disease})}{P(\text{symptom})}]$$

🧠 Meaning:

👉 “symptom দেখলে রোগ কতটা likely?”

📌 4. Why Bayes is powerful?

👉 Bayes' rule useful কারণ:

- ✓ আমরা সরাসরি **unknown probability** জানি না
 - ✓ কিন্তু **related probabilities** জানা থাকে
-

🔥 So Bayes does this magic:

👉 “causal direction উল্টে দেয়”

🧠 Example:

আমরা জানি:

- রোগ → symptom (cause → effect)

👉 কিন্তু আমরা চাই:

- symptom → disease (effect → cause)
-

Bayes solves exactly this inversion problem

5. Real-world interpretation

👉 Bayes' rule মানে:

- prior belief (আগের ধারণা)
 - evidence (নতুন তথ্য)
 - updated belief (নতুন সিদ্ধান্ত)
-

Simple flow:

Prior + Evidence → Posterior

FINAL SUMMARY

- 👉 Bayes' rule needs 3 known probabilities to compute 1 unknown probability
- 👉 It is useful because those 3 probabilities are often easier to estimate in real life
- 👉 Especially in medical diagnosis, we know:

- disease → symptom probabilities
- disease frequency
- symptom frequency

👉 But we want:

- symptom → disease probability

👉 Bayes' theorem converts causal knowledge into diagnostic reasoning

ONE LINE EXAM ANSWER

Bayes' rule is practically useful because it uses three known probabilities (prior, likelihood, and evidence) to compute an unknown conditional probability, making it

especially powerful in tasks like medical diagnosis where causal relationships are known but diagnostic probabilities are required.

4. Bayes' Law Summary

👉 Bayes' theorem AI-এর probability reasoning-এর foundation

Formula memory trick:

👉 Posterior = Likelihood × Prior / Evidence

$$P(B|A) = \frac{P(A|B)P(B)}{P(A)}$$

CLICK SUB: Bayes' in Action

5. Bayes' Rule কী লাগে?

👉 Bayes' theorem ব্যবহার করতে লাগে:

- ✓ 1 conditional probability
 - ✓ 2 unconditional probabilities
-

Example Setup:

- $P(s|m) = 0.5$
 - $P(m) = 1/50000$
 - $P(s) = 1/20$
-

Meaning (intuition):

- m = disease

- s = symptom

👉 symptom থাকলে disease কতটা likely?

Real-life use:

- Medical diagnosis 
 - Spam detection 
 - AI classification 
-

CLICK SUB: Bayes Example (Football)

Scenario:

- Team 0 wins = 65%
- Team 1 wins = 35%

Additional info:

- 30% of Team 0 wins are away
 - 75% of Team 1 wins are home
-

Question:

👉 If match is at home (Team 1 hosts), who is more likely to win?

Idea:

We are reversing probability:

👉 We know:

- $P(\text{home} \mid \text{win})$
👉 We want:
- $P(\text{win} \mid \text{home})$

Solution approach:

Use Bayes:

$$[\\begin{aligned} P(\\text{win}|\\text{home}) &= \\frac{P(\\text{home}|\\text{win})P(\\text{win})}{P(\\text{home})} \\end{aligned}]$$

Insight:

👉 Home advantage + prior win rate → final probability

CLICK SUB: Bayesian Updating

6. Real AI use: Updating belief

Bayesian AI continuously updates belief:

Example:

$$[\\begin{aligned} P(\\text{Cavity} | \\text{Toothache} \\wedge \\text{Catch}) \\end{aligned}]$$

Expanded idea:

$$[\\begin{aligned} P(\\text{Cavity} | \\text{evidence}) &= \\frac{P(\\text{evidence} | \\text{Cavity}) \\cdot P(\\text{Cavity})}{P(\\text{evidence})} \\end{aligned}]$$

Meaning:

👉 Multiple symptoms (evidence) দিলে disease probability update হয়

Example intuition:

- Toothache আছে
- Catch (dentist check) positive

👉 তাহলে cavity probability increase হয়

FINAL SUMMARY

- 👉 Bayes' theorem helps reverse conditional probability
- 👉 It updates belief using new evidence
- 👉 Formula:

$$P(B|A) = \frac{P(A|B)P(B)}{P(A)}$$

👉 Used in:

- medical diagnosis
 - AI classification
 - decision making
 - spam filtering
-

ONE LINE EXAM ANSWER

Bayes' Theorem provides a mathematical method to update prior beliefs into posterior probabilities using observed evidence, expressed as $P(B|A) = \frac{P(A|B)P(B)}{P(A)}$, and is fundamental in probabilistic reasoning and AI applications.

FINAL TAKEAWAY (super important)

👉 Bayes = “Evidence দেখে পুরনো belief update করা”

■ Problem 1: Medical Diagnosis (Classic Bayes Problem)

A certain disease affects 1 in 1000 people. A medical test is used to detect the disease. If a person has the disease, the test is positive 99% of the time. If a person does not have the disease, the test is still positive 5% of the time due to error.

A patient takes the test and gets a positive result. What is the probability that the patient actually has the disease?

🔴 Given:

- $P(D) = 1/1000 = 0.001$
- $P(\neg D) = 0.999$
- $P(+|D) = 0.99$
- $P(+|\neg D) = 0.05$

We need:

$$P(D|+)$$

◆ Step 1: Bayes' Theorem

$$P(D|+) = \frac{P(+|D)P(D)}{P(+)}$$

◆ Step 2: Find $P(+)$

$$\begin{aligned} P(+) &= P(+|D)P(D) + P(+|\neg D)P(\neg D) \\ &= (0.99)(0.001) + (0.05)(0.999) \\ &= 0.00099 + 0.04995 = 0.05094 \end{aligned}$$

◆ Step 3: Apply Bayes

$$P(D|+) = \frac{0.00099}{0.05094}$$

$$P(D|+) \approx 0.0194$$

🎯 Final Answer:

$$P(D|+) \approx 1.94\%$$

💡 Interpretation:

Even after a positive test, the probability of having the disease is still low due to rare disease occurrence and false positives.

■ Problem 2: Spam Email Detection

A spam filter classifies emails. 20% of all emails are spam. The word "free" appears in 70% of spam emails and 10% of non-spam emails.

An email contains the word "free". What is the probability that it is spam?

💡 Given:

- $P(S) = 0.2$
- $P(\neg S) = 0.8$
- $P(F|S) = 0.7$
- $P(F|\neg S) = 0.1$

We need:

$$P(S|F)$$

◆ Step 1: Bayes Formula

$$P(S|F) = \frac{P(F|S)P(S)}{\downarrow P(F)}$$

◆ Step 2: Find $P(F)$

$$\begin{aligned} P(F) &= P(F|S)P(S) + P(F|\neg S)P(\neg S) \\ &= (0.7)(0.2) + (0.1)(0.8) \\ &= 0.14 + 0.08 = 0.22 \end{aligned}$$

◆ Step 3: Apply Bayes

$$\begin{aligned} P(S|F) &= \frac{0.14}{0.22} \\ P(S|F) &\approx 0.636 \end{aligned}$$

🎯 Final Answer:

$$P(S|F) \approx 63.6\%$$

🧠 Interpretation:

If an email contains "free", there is a high chance it is spam.

■ Problem 3: Factory Quality Control

A factory produces 2 types of machines:

- Factory A produces 60% of machines, with 2% defect rate
- Factory B produces 40% of machines, with 5% defect rate

A randomly selected machine is found defective. What is the probability it came from Factory B?

🧠 **Given:**

- $P(A) = 0.6, P(B) = 0.4$
- $P(D|A) = 0.02$
- $P(D|B) = 0.05$

We need:

$$P(B|D)$$

◆ **Step 1: Bayes Formula**

$$P(B|D) = \frac{P(D|B)P(B)}{P(D)}$$

◆ **Step 2: Compute $P(D)$**

$$\begin{aligned} P(D) &= (0.02)(0.6) + (0.05)(0.4) \\ &= 0.012 + 0.02 = 0.032 \end{aligned}$$

◆ **Step 3: Apply Bayes**

$$\begin{aligned} P(B|D) &= \frac{0.02}{0.032} \\ P(B|D) &= 0.625 \end{aligned}$$

🎯 **Final Answer:**

$$P(B|D) = 62.5\%$$

🧠 **Interpretation:**

Even though Factory B produces fewer machines, defective machines are more likely to come from B.

🧠 Step 1: Evidence আসলে কী?

👉 **Evidence** = যেটা আমরা **observe** করেছি (**real-world** এ দেখা ঘটনা)

✓ এই question-এ clearly বলা আছে:

“Today, the sky is cloudy”

👉 তাই:

✓ **Evidence = Cloudy**

🧠 Step 2: Evidence চেনার golden rule 🔥

👉 প্রশ্নে খুঁজো:

- “today”
- “observed”
- “given that”
- “it is seen that”

✓ যেটা real-world observation → সেটাই evidence

🔥 Key Comparison

Term	Meaning	এই প্রশ্নে
Prior	আগে থেকে জানা	$P(\text{Rain})$
Likelihood	condition দেওয়া	$P(\text{Cloudy} \mid \text{Rain})$
Evidence	observed ঘটনা	Cloudy

Answer any 2 from 1 to 3:

1.	Scenario: A movie recommendation agent uses rules: If user likes action AND thriller → Recommend movie A If user likes comedy → Recommend movie B Task: a) Design a logical representation of the system. b) Suggest how the agent should handle multiple recommendations. c) Evaluate limitations of using propositional logic in this system.
2.	Scenario: A weather system predicts rain based on cloud conditions: • $P(\text{Rain}) = 0.3$ • $P(\text{Cloudy} \mid \text{Rain}) = 0.8$ • $P(\text{Cloudy} \mid \text{No Rain}) = 0.4$ Today, the sky is cloudy.

Questions: a) What is meant by prior probability in this scenario? b) Identify likelihood and evidence. c) Explain why uncertainty is important in this system.

✓ Question 1: Logical Agent (Movie Recommendation System)

◆ Given Rules:

- If user likes **Action AND Thriller** → **Movie A**
 - If user likes **Comedy** → **Movie B**
-

(a) Logical Representation (Propositional Logic)

প্রথমে আমরা variables define করি:

- A = user likes Action
- T = user likes Thriller
- C = user likes Comedy
- MA = Recommend Movie A
- MB = Recommend Movie B

👉 **Now rules:**

1. **(A ∧ T) → MA**
(Action AND Thriller হলে Movie A)
2. **C → MB**
(Comedy হলে Movie B)

✓ এইটাই logical representation

(b) Multiple Recommendation Handle করা

ধরো user:

- Action পছন্দ করে
- Thriller পছন্দ করে
- Comedy ও পছন্দ করে

👉 তাহলে:

- Rule 1 → Movie A
- Rule 2 → Movie B

! **Problem:**

একই সাথে 2টা recommendation আসবে

✓ **Solution ideas:**

1. **Priority system**

- যেমন: Action+Thriller বেশি strong → Movie A first
 - 2. **Multiple recommendation**
 - “You may like: A and B”
 - 3. **Ranking system**
 - Score দিয়ে sort করা
 - 4. **Ask user preference**
 - “Do you prefer action or comedy?”
-

(c) Limitations of Propositional Logic

Propositional Logic = শুধু TRUE/FALSE

Problems:

1. **No uncertainty**
 - User একটু comedy পছন্দ করে → handle করতে পারে না
2. **No degree**
 - কতটা পছন্দ → বোঝে না
3. **Rigid rules**
 - real life flexible না
4. **No learning**
 - নতুন data থেকে improve করে না

👉 তাই real system-এ probabilistic model use করা হয়

Question 2: Uncertainty (Weather Prediction)

◆ Given:

- $P(\text{Rain}) = 0.3$
 - $P(\text{Cloudy} \mid \text{Rain}) = 0.8$
 - $P(\text{Cloudy} \mid \text{No Rain}) = 0.4$
 - Today: Cloudy
-

Basic Idea (VERY IMPORTANT)

এটা হলো **Bayes Theorem problem**

আমরা জানতে চাই:

☝️ Cloudy হলে Rain হওয়ার chance কত?

🧠 (a) Prior Probability

☝️ Prior = আগে থেকে জানা probability

✓ এখানে:

- $P(\text{Rain}) = 0.3$

☝️ মানে: কোন evidence ছাড়া rain হওয়ার chance

🧠 (b) Likelihood & Evidence

✓ Likelihood:

- $P(\text{Cloudy} | \text{Rain}) = 0.8$
☝️ Rain হলে Cloudy হওয়ার chance

✓ Evidence:

- $P(\text{Cloudy})$

আমরা calculate করি:

$$\begin{aligned} P(\text{Cloudy}) &= \\ &= P(\text{Cloudy} | \text{Rain}) \times P(\text{Rain}) + P(\text{Cloudy} | \text{NoRain}) \times P(\text{NoRain}) \\ &= (0.8 \times 0.3) + (0.4 \times 0.7) \\ &= 0.24 + 0.28 \\ &= \mathbf{0.52} \end{aligned}$$

🧠 (Extra: Posterior Probability)

☝️ Cloudy দেখে Rain কত?

$$\begin{aligned} [\\ P(\text{Rain} | \text{Cloudy}) &= \frac{P(\text{Cloudy} | \text{Rain}) \cdot P(\text{Rain})}{P(\text{Cloudy})} \\] \end{aligned}$$

$$= 0.24 / 0.52$$
$$\approx 0.4615 (\approx 46\%)$$

(c) Why Uncertainty Important?

Real world = uncertain

✓ কারণ:

1. Weather 100% predictable না
2. Cloudy মানেই rain না
3. Data incomplete হতে পারে
4. Human behavior unpredictable

👉 তাই probability use করা হয়

FINAL SUMMARY (Exam Ready)

Q1:

- $(A \wedge T) \rightarrow MA$
 - $C \rightarrow MB$
 - Multiple handling $\rightarrow$ priority / ranking / multiple output
 - Limitation $\rightarrow$ no uncertainty, no flexibility
-

Q2:

- Prior $\rightarrow P(\text{Rain})$
 - Likelihood $\rightarrow P(\text{Cloudy} | \text{Rain})$
 - Evidence $\rightarrow P(\text{Cloudy})$
 - Posterior $\rightarrow 0.46$
 - Uncertainty important because real world uncertain
-